


Analiza ocjena i preporuke filmova

Analiza korisničkih ocjena i preporuke filmova po režiserima i glumcima

SISTEMI BAZA PODATAKA
IN57/2019 Sofija Merćep



Cilj projekta:

Cilj projekta je analiza preporuke filmova korišćenjem MovieLens 25M i The Movies Dataset-a skupova podataka

Fokus projekta:

Fokus projekta je na tome kako se iz korisničkih ocjena, režisera, glumaca i žanrova mogu izdvojiti filmovi koji predstavljaju dobre kandidate za preporuku.

Movies like Castle in the Sky

O platformi MovieLens

MovieLens je sistem za preporuku filmova koji korisnicima omogućava da ocjenjuju filmove i na osnovu tih ocjena dobijaju personalizovane preporuke.

MovieLens nije streaming platforma i ne služi za gledanje filmova. Njegova glavna namjena je preporučivanje filmova na osnovu korisničkog ukusa.

Podatke objavljuje GroupLens, istraživačka grupa koja se bavi sistemima preporuke i analizom korisničkog ponašanja.

Opis skupova podataka

Za projekat se koristi MovieLens 25M skup podataka.
Zove se MovieLens 25M jer ima 25 miliona korisničkih ocjena.

Pored toga sadrži:

- preko milion tagova
- oko 62.000 filmova
- oko 162.000 anonimnih korisnika

Podaci su prikupljeni u periodu od 1995. do 2019. godine.
Izvor podataka: GroupLens – MovieLens 25M Dataset

Opis skupova podataka

Za proširenje MovieLens 25M skupa koristi se **The Movies Dataset** sa Kaggle platforme. Ovaj skup podataka sadrži metapodatke za oko **45.000 filmova** iz Full MovieLens Dataset-a.

The Movies Dataset opisuje filmove kroz dodatne informacije kao što su:

- budžet i prihod filma
- datum izlaska
- popularnost
- jezici
- produkcijske kuće i države
- glumačka ekipa
- režiseri i članovi filmske ekipe
- ključne riječi koje opisuju sadržaj filma

Datoteke u MovieLens skupu podataka

Koristiće se sljedeće datoteke:

- `movies.csv` — osnovni podaci o filmovima,
- `ratings.csv` — ocjene koje su korisnici dali filmovima,
- `tags.csv` — slobodni tagovi koje su korisnici dodali filmovima,
- `links.csv` — veze ka IMDb i TMDb identifikatorima,
- `genome-tags.csv` — lista standardizovanih tagova,
- `genome-scores.csv` — relevantnost tagova za određene filmove.

Datoteke u The Movies Dataset skupu podataka

Koristiće se sljedeće datoteke:

- `movies_metadata.csv` — metapodaci o filmovima,
- `credits.csv` — glumci, režiseri i filmska ekipa,
- `keywords.csv` — ključne riječi povezane sa filmovima

Semantika kolona — filmovi i ocjene

`movies.csv`

- `movieId` — jedinstveni identifikator filma u MovieLens sistemu,
- `title` — naziv filma, često sa godinom prikazivanja u zagradi,
- `genres` — lista žanrova kojima film pripada.

`ratings.csv`

- `userId` — anonimni identifikator korisnika,
- `movieId` — identifikator filma koji je korisnik ocijenio,
- `rating` — ocjena korisnika, u rasponu od 0.5 do 5.0,
- `timestamp` — vrijeme kada je ocjena dodata.

Semantika kolona — tagovi i dodatni podaci

tags.csv

- `userId` — anonimni identifikator korisnika,
- `movieId` — film kojem je dodat tag,
- `tag` — tekstualna oznaka koju je korisnik dodao filmu,
- `timestamp` — vrijeme dodavanja taga.

links.csv

- `movieId` — MovieLens identifikator filma,
- `imdbId` — identifikator filma na IMDb platformi,
- `tmdbId` — identifikator filma na TMDB platformi.

genome-tags.csv i genome-scores.csv

- definišu standardizovane tagove i njihovu relevantnost za filmove.

Semantika kolona — The Movies Dataset

`movies_metadata.csv`

- `id` — TMDB identifikator filma,
- `title` — naziv filma,
- `release_date` — datum izlaska filma,
- `genres` — žanrovi filma,
- `budget` — budžet filma,
- `revenue` — prihod filma,
- `popularity` — mjera popularnosti filma,
- `vote_average` — prosječna TMDB ocjena,
- `vote_count` — broj TMDB glasova,
- `original_language` — originalni jezik filma,
- `production_companies` — produkcijske kuće,
- `production_countries` — države produkcije.

Semantika kolona — The Movies Dataset

Credits.csv

- **id** — TMDb identifikator filma,
- **cast** — lista glumaca,
- **crew** — filmska ekipa, uključujući režisere.

Keywords.csv

- **id** — TMDb identifikator filma,
- **keywords** — ključne riječi koje opisuju sadržaj filma

Povezivanje skupova podataka

Povezivanje dva skupa podataka vrši se preko datoteke `links.csv`.

MovieLens koristi identifikator `movieId`, dok The Movies Dataset koristi TMDB identifikator `id`.

Datoteka `links.csv` sadrži vezu između ova dva sistema:
`MovieLens movieId → links.tmdbId → TMDB id`

Na taj način se korisničke ocjene i tagovi iz MovieLens skupa povezuju sa metapodacima, glumcima, režiserima i ključnim riječima iz The Movies Dataset skupa.

Primer prostiranja podataka

Jedan film se kroz skup podataka povezuje sa ocjenama, tagovima i dodatnim identifikatorima (links.csv).

Primer veze:

Film — Ocjene

1 — *

Film — Tagovi

1 — *

Film — TMDb metapodaci

1 — 1

Prijedlog logičke šeme

Podaci o filmu

```
▼  
  _id: 1  
  title: "Toy Story (1995)"  
  ▼ genres: Array (5)  
    0: "Adventure"  
    1: "Animation"  
    2: "Children"  
    3: "Comedy"  
    4: "Fantasy"  
  ▼ external_ids: Object  
    imdbId: "0114709"  
    tmdbId: 862
```

Podaci o ocjeni

```
_id: ObjectId('665000000000000000000001')  
userId: 1  
movieId: 1  
rating: 4  
timestamp: 964982703  
▼ movie: Object  
  title: "Toy Story (1995)"  
  ▼ genres: Array (5)  
    0: "Adventure"  
    1: "Animation"  
    2: "Children"  
    3: "Comedy"  
    4: "Fantasy"
```


Prijedlog agregacija:

1. Koje Science Fiction filmove objavljene poslije 2000. godine mogu preporučiti široj publici ako imaju prosječnu MovieLens ocjenu veću od 4.0, najmanje 5.000 korisničkih ocjena, budžet veći od 50 miliona dolara i najmanje 3 glumca u cast listi?
2. Koji glumci iz prvih 3 mjesta u cast listi se najčešće pojavljuju u filmovima koji imaju prosječnu MovieLens ocjenu veću od 4.0, najmanje 1.000 korisničkih ocjena i prihod veći od budžeta?
3. Koji filmovi imaju prosječnu MovieLens ocjenu veću od 4.1, najmanje 2.000 korisničkih ocjena, TMDb popularnost manju od 15 i budžet veći od prihoda?
4. Koji režiseri imaju najmanje 3 filma sa prosječnom MovieLens ocjenom većom od 4.0, najmanje 1.000 korisničkih ocjena po filmu i genome tagom "dark", "psychological", "plot twist", "twist", "twist ending" ili "twists & turns" sa relevantnošću većom od 0.7?
5. Koje filmove mogu preporučiti korisniku userId = 123, ako tražim filmove koje taj korisnik još nije ocijenio, a koji imaju prosječnu MovieLens ocjenu veću od 4.0, najmanje 1.000 ocjena, najmanje jedan zajednički žanr i najmanje jednog zajedničkog glumca ili istog režisera sa filmovima koje je korisnik ranije ocijenio ocjenom 4.5 ili 5.0?

Uloga

Pitanja se postavljaju iz uloge analitičara za preporuku filmova na platformi za otkrivanje i preporuku sadržaja.

Cilj je da na osnovu korisničkih ocjena, tagova, žanrova, ili budžeta prepozna filmove koji su pogodni za preporuku ili pronadje odgovarajuće glumce ili režisere.

